EVALUATION REPORT

# AI WhatsApp Attendant

Demo case with fictional data. Seed 42, 300 simulated conversations, 125 held-out test phrases (109 in scope, 16 off topic) that repeat no training or dev phrase.

## 80.7%

conversations resolved with the right answer

242 of 300, no human involved

## 85.3%

intent accuracy on held-out phrases

93 of 109 test phrases, macro F1 0.85

## 7.3%

handed to a human

21 on request, 1 after 2 failed turns

## 62.5%

off-topic messages rejected

10 of 16 instead of a wrong answer

## Outcome of the 300 simulated conversations

Resolved means the bot answered the customer's real question and gave no wrong answer on the way.




| | | |
|---|---|---|
| Resolved with the right answer | **242** | 80.7% |
| Handed off on request | **21** | 7.0% |
| Handed off after failed turns | **1** | 0.3% |
| Handed off without a request | **0** | 0.0% |
| Wrong answer or wrong flow | **36** | 12.0% |
| Rejected, then the customer left | **0** | 0.0% |

**928** customer messages
3.09 per conversation

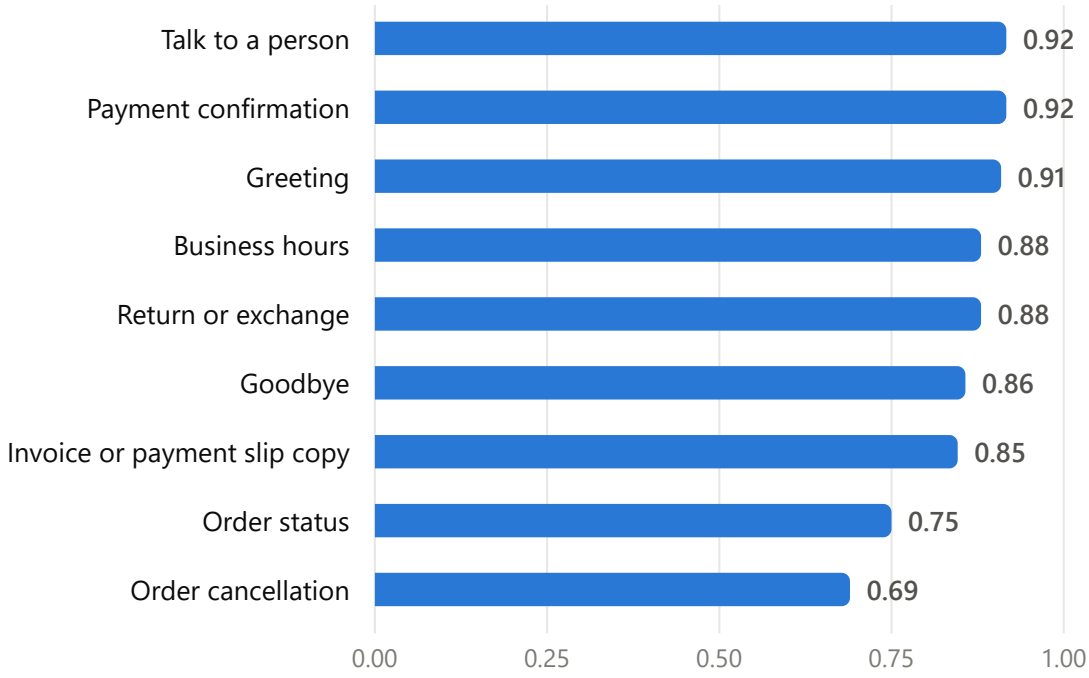
**165** order numbers asked
29 asked again after a wrong reply

**46** not understood
47 queued for the knowledge base

**0** LLM calls
the optional second layer was off in this run

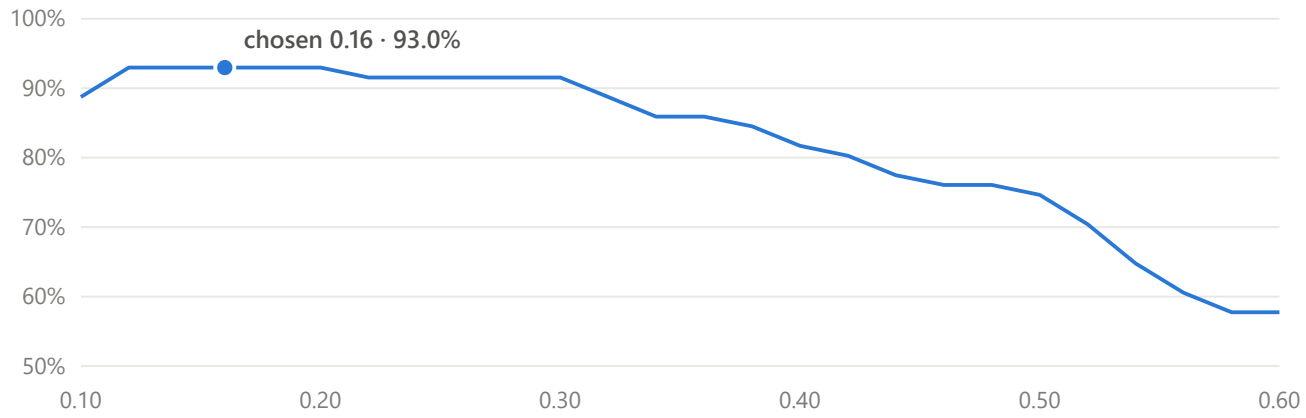
## F1 per intent on the test split

Test phrases are typed like customers type: no accents, slang, typos.



### Confidence threshold chosen on the dev split

Accuracy on the 71 dev phrases for each threshold. The median of the best thresholds (0.16) became the default; the test split was not used.




### Most frequent mistakes on the test split

| Real intent | Bot understood | Times |
|---|---|---|
| Out of scope | Order cancellation | 4 |
| Order status | Order cancellation | 3 |
| Goodbye | Not understood | 2 |
| Talk to a person | Greeting | 2 |
| Business hours | Not understood | 1 |
| Order cancellation | Goodbye | 1 |
| Invoice or payment slip copy | Order cancellation | 1 |
| Invoice or payment slip copy | Order status | 1 |

## F1 per intent on the test split

| Intent | Precision | Recall | F1 | Phrases |
|---|---|---|---|---|
| Greeting | 0.83 | 1.00 | 0.91 | 10 |
| Order status | 0.75 | 0.75 | 0.75 | 12 |
| Invoice or payment slip copy | 0.92 | 0.79 | 0.85 | 14 |
| Payment confirmation | 1.00 | 0.85 | 0.92 | 13 |
| Return or exchange | 0.92 | 0.85 | 0.88 | 13 |

| Intent | Precision | Recall | F1 | Phrases |
|---|---|---|---|---|
| Order cancellation | 0.56 | 0.91 | 0.69 | 11 |
| Business hours | 0.85 | 0.92 | 0.88 | 12 |
| Talk to a person | 1.00 | 0.85 | 0.92 | 13 |
| Goodbye | 0.90 | 0.82 | 0.86 | 11 |

## Data and method

| | |
|---|---|
| Intents in the knowledge base | 9 |
| Training examples (knowledge base) | 110 |
| Dev split (threshold only) | 61 in scope, 10 off topic |
| Test split (reported numbers) | 109 in scope, 16 off topic |
| Leaked phrases (same words, or cosine of 0.95 or more) | 0 |
| Customer messages simulated | 928 |
| Messages queued for learning | 47 |
| LLM calls in this run | 0 |

- The classifier learns only from the knowledge base examples.
- The dev split chooses the confidence threshold; the test split was frozen and committed before any evaluation code existed, and has only lost phrases since.
- No test phrase is the same model input as a training or dev phrase: the same words once stopwords are dropped, in any order, or a cosine of 0.95 or more, count as a leak and were removed.
- Simulated customers draw their messages from the test split and add typos, filler words and order numbers at random, with a fixed seed. They rephrase once when rejected and answer the cancellation question honestly.
- A conversation counts as resolved only when the bot answered the main question and gave no wrong answer; a wrong answer is a failure even if the right one came later.

## Sample conversations

**Order status: Resolved with the right answer**

a transportadora já pegou meu pedido? urgente

Para localizar o pedido, me informe o número dele. São 6 dígitos e ele está no e-mail de confirmação da compra.

Order cancellation · 0.18

nº 417241

Confirma o cancelamento do pedido 417241? Responda sim ou não.

Order cancellation · 1.00

nao, não quero cancelar

Tudo bem, não fiz nenhuma alteração. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, pagamento, troca, cancelamento ou horário.

Order cancellation · 1.00

cadê o meu pedido?

O pedido 417241 está entregue, com o recebimento registrado pela transportadora. O código de rastreio também foi enviado para o seu e-mail.

Order status · 0.52

**Invoice or payment slip copy: Wrong answer or wrong flow**

oi, tudo certo?

Olá, aqui é o atendimento da Loja Exemplo. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, pagamento, troca, cancelamento ou horário. Como posso ajudar?

Greeting · 0.58

prciso da nf da compra pra empresa!!, pedido 906769

Confirma o cancelamento do pedido 906769? Responda sim ou não.

Order cancellation · 0.25

não

Tudo bem, não fiz nenhuma alteração. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, pagamento, troca, cancelamento ou horário.

Order cancellation · 1.00

o boleto não chegou no meu email

Abri a solicitação de troca ou devolução do pedido 906769. A etiqueta de postagem gratuita chega no seu e-mail e, quando o produto chegar ao nosso centro, a troca ou o reembolso sai em até 5 dias úteis.

Return or exchange · 0.36

**Talk to a person: Handed off on request**

boa tarde, preciso de uma ajuda

Olá, aqui é o atendimento da Loja Exemplo. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, pagamento, troca, cancelamento ou horário. Como posso ajudar?

Greeting · 0.80

quero falar com o setor responsável ...

Certo, vou transferir a conversa para um atendente, que responde de segunda a sexta, das 8h às 18h. O histórico fica registrado e você não precisa repetir nada.

Talk to a person · 0.81

**Return or exchange: Handed off after failed turns**

oi, bom dia

Olá, aqui é o atendimento da Loja Exemplo. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, pagamento, troca, cancelamento ou horário. Como posso ajudar?

Greeting · 0.85

quero trabalhar com vocês

Não consegui identificar o assunto. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, confirmação de pagamento, troca, cancelamento ou horário de atendimento.

Not understood · 0.09

vieo faltando uma peça urgente

Vou transferir a conversa para um atendente, que responde de segunda a sexta, das 8h às 18h. O histórico fica registrado e você não precisa repetir nada.

Not understood · 0.11

---

Demo case: fictional store, customers, phones and orders. No message was sent to a real person. Generated by python -m whatsapp_attendant evidence.