EVALUATION REPORT

AI WhatsApp Attendant

Demo case with fictional data. Seed 42, 300 simulated conversations, intent accuracy measured on 137 phrases never used in training.

72.0%

conversations resolved with the right answer

216 of 300, no human involved

86.8%

intent accuracy on never-seen phrases

105 of 121 test phrases, macro F1 0.87

7.0%

handed to a human

17 on request, 4 after 2 failed turns

62.5%

off-topic messages rejected

10 of 16 instead of a wrong answer

Outcome of the 300 simulated conversations

Resolved means the bot answered the customer's real question.



Resolved with the right answer	**216**	72.0%
Handed off on request	**17**	5.7%
Handed off after failed turns	**4**	1.3%
Handed off without a request	**0**	0.0%
Answered a different question	**63**	21.0%

829 customer messages
2.76 per conversation

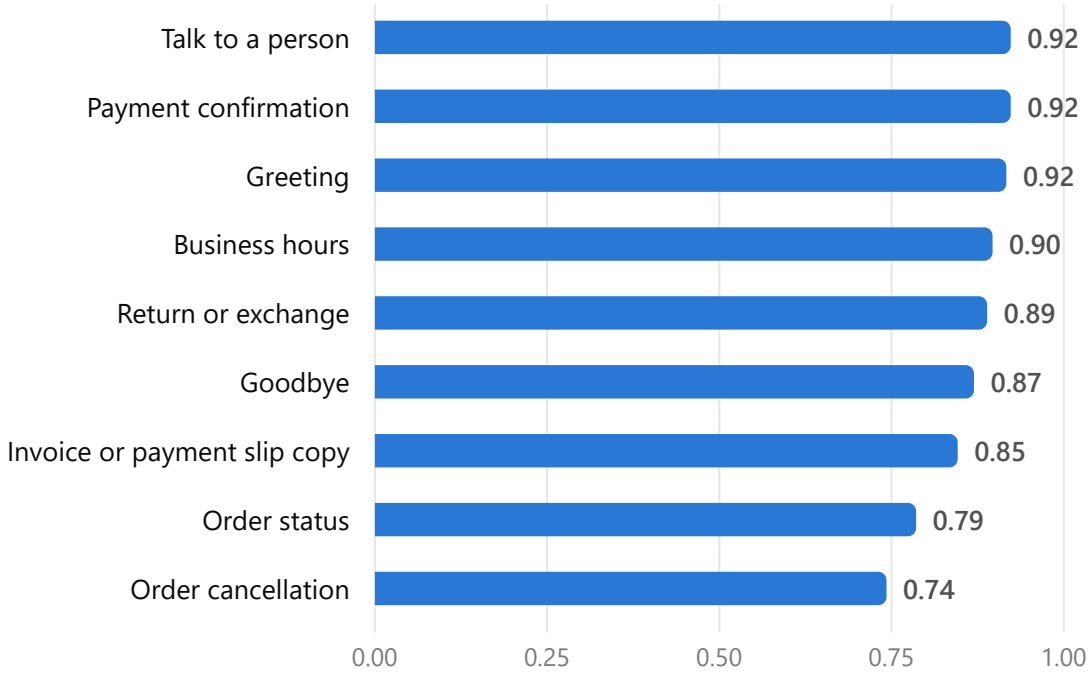
142 order numbers asked
33 asked again after a wrong reply

44 not understood
48 queued for the knowledge base

0 LLM calls
the optional second layer was off in this run

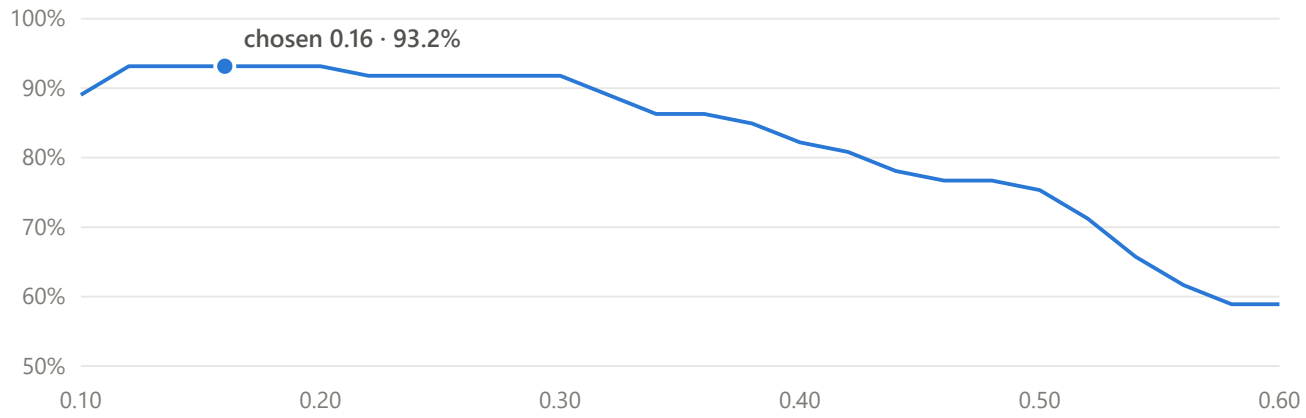
F1 per intent on the test split

Test phrases are typed like customers type: no accents, slang, typos.



Confidence threshold chosen on the dev split

Accuracy on the 73 dev phrases for each threshold. The median of the best thresholds (0.16) became the default; the test split was not used.



Most frequent mistakes on the test split

Real intent	Bot understood	Times
Out of scope	Order cancellation	4
Order status	Order cancellation	3
Goodbye	Not understood	2
Talk to a person	Greeting	2
Business hours	Not understood	1
Order cancellation	Goodbye	1
Invoice or payment slip copy	Order cancellation	1
Invoice or payment slip copy	Order status	1

F1 per intent on the test split

Intent	Precision	Recall	F1	Phrases
Greeting	0.85	1.00	0.92	11
Order status	0.79	0.79	0.79	14
Invoice or payment slip copy	0.92	0.79	0.85	14
Payment confirmation	1.00	0.86	0.92	14
Return or exchange	0.92	0.86	0.89	14

Intent	Precision	Recall	F1	Phrases
Order cancellation	0.62	0.93	0.74	14
Business hours	0.87	0.93	0.90	14
Talk to a person	1.00	0.86	0.92	14
Goodbye	0.91	0.83	0.87	12

Data and method

Intents in the knowledge base	9
Training examples (knowledge base)	110
Dev split (threshold only)	63 in scope, 10 off topic
Test split (reported numbers)	121 in scope, 16 off topic
Phrases shared between splits	0
Customer messages simulated	829
Messages queued for learning	48
LLM calls in this run	0

- The classifier learns only from the knowledge base examples.
- The dev split chooses the confidence threshold; the test split was frozen and committed before any evaluation code existed.
- Simulated customers draw their messages from the test split and add typos, filler words and order numbers at random, with a fixed seed.
- A conversation counts as resolved only when the bot answered the main question; a confident wrong answer is counted as a failure, not as a success.

Sample conversations

Order status: Resolved with the right answer

boa tarde, preciso de uma ajuda

Olá, aqui é o atendimento da Loja Exemplo. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, pagamento, troca, cancelamento ou horário. Como posso ajudar?

Greeting · 0.80

quero trabalhar com vocês

Não consegui identificar o assunto. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, confirmação de pagamento, troca, cancelamento ou horário de atendimento.

Not understood · 0.09

tem código de rastreamento? pfv, pedido 781453

O pedido 781453 está em separação no estoque, com envio previsto para o próximo dia útil. O código de rastreio também foi enviado para o seu e-mail.

Order status · 0.53

Invoice or payment slip copy: Answered a different question

oiee

Olá, aqui é o atendimento da Loja Exemplo. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, pagamento, troca, cancelamento ou horário. Como posso ajudar?

Greeting · 0.20

o código de barras do boleto não funciona por favor

Para localizar o pedido, me informe o número dele. São 6 dígitos e ele está no e-mail de confirmação da compra.

Order status · 0.38

913694

O pedido 913694 está em separação no estoque, com envio previsto para o próximo dia útil. O código de rastreio também foi enviado para o seu e-mail.

Order status · 1.00

obrigadão

Eu que agradeço. Se precisar de algo mais, é só mandar mensagem por aqui.

Goodbye · 0.41

Talk to a person: Handed off on request

tem como falar com uma pessoa? pfv

Certo, vou transferir a conversa para um atendente, que responde de segunda a sexta, das 8h às 18h. O histórico fica registrado e você não precisa repetir nada.

Talk to a person · 0.71

Business hours: Handed off after failed turns

oi, bom dia

Olá, aqui é o atendimento da Loja Exemplo. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, pagamento, troca, cancelamento ou horário. Como posso ajudar?

Greeting · 0.85

tem plantão no fim de semana?

Não consegui identificar o assunto. Posso ajudar com status do pedido, segunda via de boleto ou nota fiscal, confirmação de pagamento, troca, cancelamento ou horário de atendimento.

Not understood · 0.06

agradeço

Vou transferir a conversa para um atendente, que responde de segunda a sexta, das 8h às 18h. O histórico fica registrado e você não precisa repetir nada.

Not understood · 0.06

Demo case: fictional store, customers, phones and orders. No message was sent to a real person. Generated by python -m whatsapp_attendant evidence.